

중 간 발 표 — 2026년 4월

GPU 클러스터 추론 워크로드를 위한 스케줄링 및 배치 정책 공동 최적화

추론 지연시간 SLO 준수와 GPU 활용률 극대화를 위한 통합 정책 설계

윤영준 · 전현성 · 박준열 · 부광민

젠슨항팀 · 컴퓨터종합설계

