

EXECUTIVE SUMMARY

기존 GPU 스케줄러는 추론 SLO를 체계적으로 위반하며, 비대칭 스코어링이 이를 해결한다

학습(training)에 최적화된 기존 정책을 추론(inference)에 그대로 적용하면, 응답 시간 보장(SLO)이 무너진다. SLO 마감일 기반의 비대칭 가중치로 긴급 작업을 즉시 처리한다.

문제

추론은 짧은 실행시간과 엄격한 SLO를 요구하나, FIFO/SRTF/LAS는 "언제까지 끝나야 하는가"를 전혀 고려하지 않는다.

접근

SLO 마감까지의 여유(slack)를 비대칭 스코어링한다. 위반 임박 시 10× 가중치로 즉시 우선 실행하고, 배치 정책과 공동 최적화한다.

검증

Blox 시뮬레이터 위에 4종 스케줄러를 구현하고, 실제 Philly Trace(117K jobs) 고부하 환경에서 SloScoring이 FIFO 대비 JCT 62% 감소를 달성했다.

4

스케줄링 정책 구현

117K

실제 Philly Trace 작업

10×

SLO 위반 가중치 (α/β)

62%↓

JCT 감소 (vs FIFO)