

PROBLEM DEFINITION

추론과 학습은 근본적으로 다른 워크로드이다

같은 GPU 클러스터 위에서 돌아가지만, 요구하는 것은 정반대다.

EXHIBIT 1

학습 vs 추론 워크로드 비교

특성	학습 (TRAINING)	추론 (INFERENCE)	시사점
실행 시간	수 시간 ~ 수 일	수 초 ~ 수 분	스케줄링 빈도 ↑↑
도착 패턴	소수의 대규모 작업	다수의 소규모 작업	큐 경쟁 심화
핵심 지표	총 완료 시간 (JCT)	응답 시간 보장 (SLO)	마감 시한 개념 필요
실패 비용	재학습 (체크포인트 복구)	사용자 이탈, SLA 위반	즉각 비즈니스 영향
선점 가능성	가능 (체크포인트 저장)	불가 (응답 소실)	선점 기반 스케줄링 불가

SO WHAT

학습용으로 설계된 FIFO, SRTF, LAS는 "이 작업이 언제까지 끝나야 하는가"를 전혀 고려하지 않는다. 추론 워크로드에는 SLO 마감 시한을 직접 반영하는 새로운 스케줄링 기법이 필요하다.