

기존 스케줄러는 추론 SLO와 배치를 동시에 최적화하지 못한다

학습 중심 스케줄러는 SLO 자체가 부재하고, 추론 서빙 시스템은 클러스터 수준 배치 공동 최적화가 없다.

EXHIBIT 2

관련 연구 비교 분석

논문	스케줄링	배치	대상	핵심 한계
학습 중심 스케줄러				
Tiresias NSDI'19	LAS + 2D 우선순위	Consolidated	Training	SLO 개념 부재
Pollux OSDI'21	Goodput 적응형	배치 크기 공동 조정	Training	SLO 개념 부재
Gavel OSDI'20	공정성 기반	Heterogeneity-aware	Training	추론 특화 아님
추론 서빙 시스템				
Clockwork OSDI'20	예측 기반 SLO	단일 모델	Inference	클러스터 배치 미지원
Shepherd OSDI'23	SLO-aware 서빙	모델 레벨	Inference	배치 공동 최적화 없음
프레임워크				
Blox EuroSys'24	모듈러 프레임워크	교체 가능	Training	정책 미제안, 추론 미검증
본 연구 Ours	비대칭 SLO 스코어링	부하 인식형	Inference	단일 클러스터 가정

OUR CONTRIBUTION

학습 중심 스케줄러에는 SLO가 부재하고, 추론 서빙 시스템에는 클러스터 수준 배치 최적화가 없다. 본 연구는 **SLO 마감일을 스케줄링에 직접 반영하면서 배치 정책과 공동 최적화**하는 최초의 추론 특화 연구다.