


SLO 스코어링과 부하 인식 배치가 파이프라인으로 연동된다

스케줄러가 SLO 기반 우선순위를 결정하면, 배치 정책이 GPU 부하를 고려하여 할당한다.

EXHIBIT 4

파이프라인 아키텍처



Module 3: ML 기반 JCT 예측 향후 연구

32
노드

4
GPU / 노드

300_s
라운드 주기

gRPC
통신 프로토콜