

고부하 환경에서 SloScoring이 FIFO 대비 JCT 62% 감소, Oracle(SRTF) 수준 달성

EXHIBIT 5

Scheduling Policy Comparison (Real Philly Trace)

Load = 8 jobs/hr | 32 nodes × 4 GPUs | Microsoft Philly Trace (117K jobs) | 100 tracked jobs

정책	AVG JCT (S)	FIFO 대비	AVG 응답성 (S)
FIFO	147,361	기준	94,709
LAS	179,238	+21.6%	441
SRTF	55,255	-62.5%	1,519
SloScoring	55,486	-62.3%	468

정책	MEDIAN JCT	P95 JCT	P99 JCT
FIFO	109,726	310,583	529,336
LAS	17,343	217,283	4,615,936
SRTF	17,343	217,283	468,136
SloScoring	17,343	217,283	431,536

핵심 발견: SloScoring은 Oracle(SRTF)과 동등한 JCT를 달성하면서, 응답성은 SRTF(1,519s) 대비 3.2배 빠른 468초. P99에서도 SRTF보다 8% 낮은 tail latency.

ANALYSIS

정책 간 차이 해석

1. FIFO: Head-of-line blocking

긴 작업이 GPU를 점유하면 뒤의 짧은 작업이 94,709초(26시간) 대기. 응답성 최악.

2. LAS: Preemption 역설

짧은 작업은 즉시 시작(441s)하지만, 긴 작업의 반복 preemption으로 P99 JCT가 4,615,936초로 폭증.

3. SloScoring: 최적 균형

SRTF급 JCT + LAS급 응답성을 동시 달성. SLO 마감 기반 우선순위가 Oracle 수준 성능을 비Oracle 방식으로 구현.

SO WHAT

SloScoring은 작업 소요시간을 미리 알 필요 없이(non-Oracle) Oracle 수준의 JCT와 최고 수준의 응답성을 동시에 달성한다.